忆时塔（Chronomem）实证评估：召回保持、压缩行为与递归总结的边界

YSTYLE[1] · ORCID：0009-0009-6929-0070 · lxy5266@live.com
DeepSeek V4.1 Flash[2] · AI 共同作者

[1] *position 论文（AiraXiv 2610.0035）的实证配套。实现、评估工具与原始结果归档见* `https://atomgit.com/ystyle/chronomem`*。本文为中文审阅版；**投稿以英文版为准**。* [2] *AI 共同作者（与 AiraXiv 预印本的署名一致）。详见文末 AI 使用披露。*

摘要

忆时塔的 position 论文提出了一份评估计划，但没有给出任何测量。本文把它执行了。评估对象是一个时间分层的外部记忆服务——它区分**精确回想**（沿引用链走到原始条目，不调用 LLM）与**语义回想**（读 LLM 生成的窗口摘要）——本文沿三条轴线评估：召回如何随事实的年龄退化、递归总结链保留了多少信息、以及系统在两个月真实使用中究竟记住了什么。

三个发现。**（1）近因基线的失效是结构性的，不是渐进的。** 有界近因窗口在滞后一天时满分，随后直接归零；对六档窗口的消融显示断崖随容量移动（20 条 → 1 天；200 条 → 7 天）。一次性压缩的得分**完全取决于它保留了什么**：保留每项取值的变体答对 100%，而把取值转述掉的变体在每一档都是零——**100 分的差距只由每问 11 个 token 造成**（196 对 185）。压缩里承重的是**条目与取值之间的对应关系**。分层的精确回想在整个 14 天跨度上保持 100%，且跨 seed 零方差。

（2）递归步的保真度取决于输入多样度，而非层级。 用正确的口径测量（同一项目、同一 7 天窗口）显示：输入只有一天时，该步**多数情况下选择不压缩**——68% 的此类样本长度比 ⩾0.95（多份与输入逐字相同），整体数量保留 85%、长度比 0.90（但仍有 19% 确实压缩了）。输入达到两天及以上时该步真正压缩（0.54 倍），数量保留降到 59%、因果连接词降到 53%。糊在一起平均时，单天样本会把保真度抬高。

（3）两个月真实使用中，活下来的是名字，不是数字。 一项盲测——agent 只被允许查阅记忆服务、不得访问代码仓库——**6/6 答对了**预先准备的问题，全部经由无 LLM 的路径，且包含精确数字。但沿摘要链上升时，最先牺牲的是量化证据与因果机制，专有名词与标识符存活最久。本文还报告了两个测量陷阱，它们在被发现前都产出了貌似可信的错误结果：一个长度假象让**更粗的层级看起来更保真**，一个分组错误让单天输入主导了平均值。

最后，我们报告一个关于评估方法本身的负面结果：独立的 LLM 判定者给出了具体主张，但这些主张经不起核验——我们深入核验的两个主张**都是错的**，且都朝**夸大丢失**的方向偏。因此本文结论建立在机械的、可复现的测量之上，判定者的输出只用于指示该往哪里看。

1. 引言

position 论文把忆时塔介绍为一个时间分层的外部记忆服务，并陈述了它的核心设计主张：**回想不是单一操作**。**精确回想**沿物化引用链走到原始条目，不调用 LLM；**语义回想**读 LLM 生成的摘要，是唯一真正压缩粗窗口的形态。它以一份评估计划收尾，没有任何结果。

本文报告这些结果。该计划有三部分，逐一回应：

- **（i）** 与扁平记忆和一次性压缩的受控对照，考察召回准确率与 token 成本；
- **（ii）** 沿摘要链的语义漂移研究；
- **（iii）** 在作者自己的持续部署上考察工作日志用例。

有两点使这份评估不同于一般的合成基准练习。其一，第（iii）部分跑在一个已持续积累约两个月真实记录的部署上，语料不是编造的。其二，在执行第（ii）部分时我们发现，**最直觉的测量方式是错的，且错到会反转结论**——我们把修正的细节一并报告，因为测量方法本身是结果的一部分。

我们还报告一个方法层面的负面结果（§6）。我们在同一批材料上跑了独立的 LLM 判定者；在我们深入核验的两个具体主张中，**两个都错了**，且都高估了信息丢失。这不是说判定者无用——它们指向了两个真实且值得追查的现象——但它确实意味着它们的计数不可引用，也正是本文全程依赖机械测量的原因。

1.1 贡献清单

1. 一次覆盖**五条臂**的受控对照——近因、一次性压缩、精确下钻、天级摘要与**周级摘要**——表明近因基线的退化是**容量断崖**而非渐进衰减，并由六点消融验证（§3）。
2. 对**递归总结步**的修正测量，表明其保真度由*输入多样度*决定：单输入步通常**复述**其输入而非压缩它（68% 长度比 ⩾0.95，19% 确实大幅压缩），多天步则把文本减半并丢掉约 40% 的数量（§4）。
3. 在真实数据上刻画**什么能沿链存活**：标识符活得比因果连接词久，因果连接词活得比量化证据久（§5）。
4. 一项盲测证实**无 LLM 路径足以精确召回**数月前的具体操作性事实，评分依据是独立建立的标准答案（§5.1）。
5. 一个关于 LLM 判定者的**方法论负面结果**，以及两个带修正记录的测量陷阱（§6）。

---

2. 方法

2.1 两份刻意不同的语料

合成 trace。 一个带 seed 的生成器（`bench/gen_trace.py`）产出 N 个模拟日的 agent 活动：每天产生少量**事实**（一条带记录结果的决策）加上填充活动，另有一套探针问题询问更早日子里的事实。开发过程中由测量确立的约束：

- **答案按轮转分配**，而非均匀随机：小探针集上的均匀抽样会聚集，9 个探针里曾有一个选项占 7 个（78% 的多数类基线，不留任何检出真实差异的余地）。轮转把该基线压到约 1/|选项数|。
- **每天的主题不重复抽取。** 同一天重复一个主题会让「第 N 天 X 选了什么」产生歧义；54 个（天，主题）组合中有 6 个歧义，而它们解释了分层后端**每一次**失分——系统确实记住了事实，是抽取器取了另一个。
- **探针永远回看，且滞后随运行增长。** 当天探针会被任何近因窗口答出（20 条窗口得 7/9）；固定的短滞后同样会被任何有界窗口答出（在 30 天 trace 上，1 天滞后时 20 条窗口仍得 90.6%）。因此滞后随日号增长，而这正是分层存储应当取胜的那条轴。
- 每个事实在文本里携带一个**不透明的引用号**（`ref ZQ01`）。摘要会逐字保留它，使抽取无歧义——按（主题，天）定位并不可靠，因为摘要的散文结论惯常把多个主题与多个选项写进一句话。

部署语料。 作者自己的忆时塔部署，自 2026-08-29 起连续运行，单用户。评估时它持有 480 条工作日志、1201 条 agent 活动记录与 63 条教训记录，工作日志有 37 个天级与 6 个周级摘要窗口。该语料没有标准答案，因此用于**存活**测量（§4、§5）而非准确率。

2.2 五条吃同一份输入的后端

后端	机制
`flat-recency`	保留全部，但只暴露最近的 20 条
`one-shot-compaction`	每 2 天把历史重写成一份运行简报，丢弃细节
`chronomem-exact`	沿引用链下钻到原始条目（不调用 LLM）
`chronomem-day`	读**天级**摘要，即事实自己所在窗口的那一条
`chronomem-week`	读包含该事实的**周级**摘要

五条臂吃同一份 trace、答同一组探针，并由**同一个抽取器**读取——弱抽取器会同等压低所有臂，从而保住对照；而每条臂各配一个读取器会把两者混淆。

一条曾经缺失的臂，以及它为何要紧。 我们第一版对照**没有粗粒度摘要臂**：摘要臂只读*天级*摘要。对一篇主张关乎*分层*的论文，这是实打实的缺口——被命名为「分层」的那一侧只测了一层，而粗层——那个本该以信息换跨度的东西——**从未被提问过**。因此我们补了第五条臂 `chronomem-week`，它从包含该事实的周级摘要作答。

两条摘要臂不是同一测量的两种粒度。天级臂读事实所在的窗口，问题与材料范围一致；周级臂读一个覆盖另外六天的窗口，答案是被压缩后的若干项之一。这个不对称恰恰是架构所主张的取舍，只有两条臂都在才看得见。

2.3 「滞后」的含义，以及为何分桶是区间

探针按滞后（事实与提问之间的天数）分桶。桶边界是 0/1/2/3/5/7/14/30/60，所以标着 7 的桶实际容纳滞后 7–13 天，而 30 天 trace 上最后一桶包含 29 天的探针。表格报告真实区间（`7-13`、`14-29`）：把下界当成滞后本身会引出数据并不支持的容量结论。

2.4 测量这条链：三次尝试，两次是错的

这一点值得明写，因为错误版本产出过可信、看起来可发表数字。

尝试 1——整天对整周。 保留率算出来是 81–84%，暗示粗层几乎无损。这不是有效比较：一个周包覆盖 5–7 天、比天包长约 3.4 倍，所以它既包含被测当天，又包含另外六天。目标文本更大，某个 token 就更有可能出现，而这与压缩无关。在一个把整天对整周的变体里，这个假象强到让**更粗的层级看起来比更细的还保真**（数量上是 42% 对 29%）——一个本应立即引起怀疑的结果。

尝试 2——单独一天对该周的对应项目段。 仍不对等：周段覆盖整周。

尝试 3（本文采用）。 把两侧都限制到**同一项目、同一 7 天窗口**——这才是递归真正做的变换，因为总结器按 group key 聚合某个项目的子摘要。只有到这一步，真正要考察的效应才显现（§4）。

2.5 机械的 token 存活

为避免评判散文，存活是**按类别统计 token** 来测量的：

- **数量**——两位及以上的数字、比例、小数（年份作为标签排除）；
- **符号**——反引号标识符、`--flag`、驼峰与下划线命名；
- **因果**——标记推理的连接词（因为／由于／根因／导致／因此／所以／退化成／…）。

对每一层，我们报告更细层 token 仍存在的比例。这是客观且可复现的。它不判断人类是否会说某个事实「存活」了，它测量的是信息的**具体载体**是否还在。

全文严格区分 `absent`（该层存在但略去了该事实）与 `missing`（该窗口根本没有摘要）。把二者混为一谈会把「未生成」报成信息丢失——开发过程中这个错误犯过两次，一次在此处，一次在更早的漂移研究中。

我们尝试了互补的语义指标。工具是好的，我们架在它上面的设计不是——两半都值得报告。 评审对 token 计数的反对意见是：它把词汇保留与语义保留混为一谈——换个说法复述的事实会被记成丢失，而 token 尚在、语义却反转的事实会被记成保留。自然的修法是基于 embedding 的度量——某层文本与事实的相似度，对照另一窗口的对照事实。

先说工具，因为它很容易搞错。 我们最初的运行得到：

探针	余弦相似度
完全相同	1.0000
语义相近	0.9772
主题相关	0.9901
完全无关（「时序数据库存储带时间戳的数据」对「午饭吃了西红柿炒蛋」）	**0.9758**

整个语义谱系只有 **0.0014** 的跨度，而同一性是 1.0：这个 embedding 无法把无关与相关文本分开，因此由它算出的一切 margin 都是噪声。原因在**服务配置**而非数据——端点启动 `llama-server` 时在模型 preset 里写了 `pooling = cls`，**覆盖了 GGUF 自己声明的 `qwen3.pooling_type = 3`（LAST）**，而那才是 Qwen3-Embedding 训练时用的池化。**我们起初把它当成「改不动的共享基础设施」而放弃——那是过早放弃。** 去掉这行覆盖只是一处一行的改动，同样的探针随即给出：

探针	`pooling = cls`	模型默认（LAST）
完全相同	1.0000	1.0000
语义相近	0.9772	**0.8065**
主题相关	0.9901	0.6553
完全无关	0.9758	**0.2572**
跨度	**0.0242**	**0.7428**

我们先前宣布「不可用」的指标变成了可用。`semantic_survival.py` 现在**除非这项可分离性自检通过就拒绝运行**（完全相同 ≫ 换述 ≫ 无关，跨度 > 0.3），因此配置错误的端点会**响亮地失败**，而不是静默产出 margin。

再说被「好用的工具」暴露为错误的设计。 embedding 修好后，我们测了 30 条事实对其自身窗口与对其它窗口对照事实的相似度。日/周 margin 分别是 +0.049 与 −0.056，而 token 指标与语义指标的 15 处分歧中，**15 处全是**「token 说存活、语义说丢失」——正是评审预判的方向。但经检查，这**不是对丢失的测量**：

量	值
事实对其**自身**周窗口的相似度	0.632
事实对**对照**周窗口的相似度	**0.687**

一个比事实本身更像目标窗口的对照，不能充当基线。 原因在输入里就看得见：所谓「事实」是整段 `outcome` / `decisions` 字段（170–273 字符、带 ①②③ 编号、按工作日志口吻写），而目标文本是**摘要**；对照事实又取自同批项目的相邻两天，与目标**共享文体与词汇**。负的周 margin 与「摘要读起来不像原始记录字段」同样吻合，而这个测量无法区分二者。**因此我们把它作为失败的测量报告，而不是作为支持**——这一点在此格外要紧，因为一个「15 比 0」且方向正合评审预期的结果，正是最容易被相信的那类发现。

怎么修，以及我们没做什么：对照事实换到不同文体与时期、把事实改写为摘要自身的语域，或改用 **QA 式探针**（提一个只能由该事实回答的问题并对答案打分）而非相似度 margin。最后一种最有希望——问题与摘要在语域上可比，而记录字段与摘要不可比。

2.6 总结器配置

评审明确要求提供，且上面的方差只有对照它才可解读：

项	值
模型	`qwen3.5-4b`（Q4_K_M GGUF，由 llama.cpp 以 OpenAI 兼容端点提供）
采样温度	**0.7 —— 端点默认；客户端不传 temperature**
seed	不传（端点默认）
上下文（`--ctx-size`）	131072（`CHRONOLOG_SUMMARY_CONTEXT_TOKENS`）
输出上限	4096 token（`CHRONOLOG_SUMMARY_MAX_TOKENS`）
推理	关闭（`chat_template_kwargs.enable_thinking=false`，`CHRONOLOG_SUMMARY_NO_THINK`）
单次调用输入上限	40000 token；每个作业最多 8 次调用
provider	`openai`

客户端**不请求确定性解码**，所以每次总结都是从温度 0.7 分布里的一次新采样。我们**没有**尝试调低它： 部署的摘要是无人值守的调度器生成的，冻结温度会让所报告的保持率描述一个部署并不使用的配置。 因此方差是**按系统实际运行方式**报告的属性，也正是 day/week 两臂按分布而非点估计来读的原因。

2.7 隔离

合成实验会写入，因此其客户端在**构造时拒绝**生产端口。真实语料读取器则**默认指向生产**——真实语料只存在于那里——因此它只允许只读工具，且这一点由代码强制而非仅写在文档里。开发过程中曾有一个默认指向生产，导致一份合成 trace 被写进线上存储；它已被移除，并加上了这道守卫。

---

3. 召回保持：基线的失效是结构性的

3.1 设置

30 天合成 trace，300 事件、32 探针、三个 seed（7/11/23）。按滞后桶统计准确率并对 seed 取平均；`±` 是跨 seed 标准差。图 1 画出形状，表格给出数字。

3.2 结果

滞后（天）	近因窗口	一次性压缩（破坏性）	一次性压缩（保守）	精确	天级摘要	周级摘要
1	100%	0%	100%	**100%**	100%	0%
2	0%	0%	100%	**100%**	50%	0%
3–4	0%	0%	100%	**100%**	25%	0%
5–6	0%	0%	100%	**100%**	25%	0%
7–13	0%	0%	100%	**100%**	57.1%	28.6%
14–29	0%	0%	100%	**100%**	66.7%	33.3%
整体	6.2%	**0.0%**	**100.0%**	**100.0%**	**53.1%**	**18.8%**

与之前一致，精确回想在每一桶都是 100%。两条摘要臂是单次运行（单个 seed），且每桶的探针数只有 2–14 个，所以**分桶数字噪声大，总数更可信**。

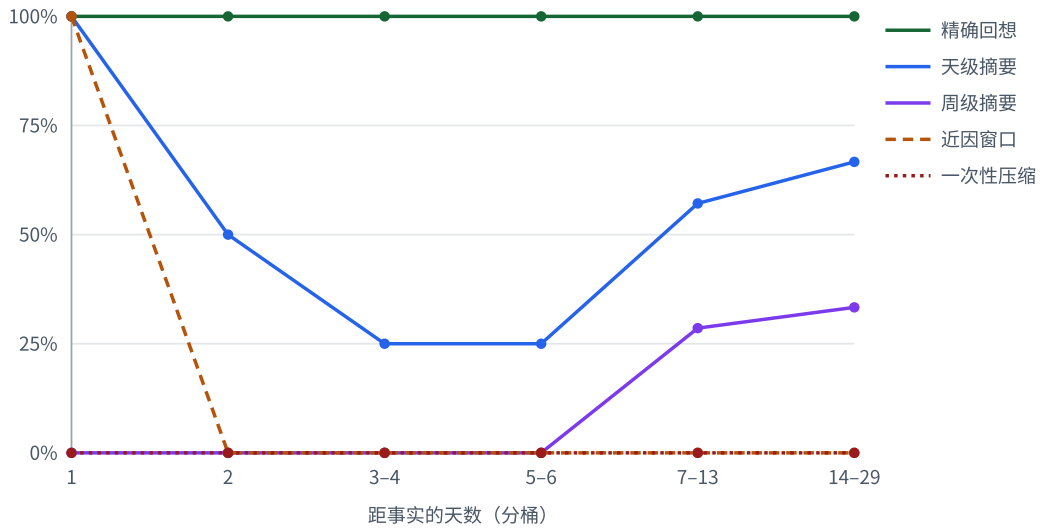


图 1. 各臂的召回保留率 vs 滞后（seed 7）。精确回想全程平在 100%——它**不随事实变老而衰减**。近因基线在滞后一天时满分、从第二天起归零，是断崖而非斜坡。一次性压缩在每一档都是零，**包括最近的窗口**。两条摘要臂会丢信息但**非单调**下降，因为摘要在生成时即定形、之后不随年龄改变（§3.2c）。线条以实线/虚线区分，颜色丢失时仍可辨。

三点观察，按「有多出乎意料」递减排列。

（a）**近因基线的跌落是断崖，不是衰减。** 它在滞后 1 天时满分，从第 2 天起为零。窗口容纳 20 条、trace 每天产生约 10 条事件，边界因此落在约 2 天处。跨越这条边界时 **内容本身没有任何变化**——那段信息只是不在目标文本里。

（b）一次性压缩在所有档位都是零——但这个零是压缩器实现的属性，不是压缩策略的属性。 这是对我们初稿最尖锐的质疑，而它说得对：我们把压缩器写成把取值转述掉，这个零里有我们自己的成分。为把两者分开，我们加了**保守压缩臂**：同样的压缩节奏，但保留每一个「引用号→取值」配对，只丢上下文与散文：它不仅丢失陈旧细节，**连最近的细节也丢**。在我们的实现里，压缩过程把每个窗口改写成 转述（「就 X 做了一项决定」），因此在滞后 1 天时选项字母同样不出现。该实现是**刻意** 破坏性的——保真度正是被测属性——更早的一版保留了决策原句、得了 100%，而经检查它 根本没有压缩，只是在丢弃填充内容。

（c）分层存储的损失是压缩损失，不是时间衰减。 精确回想在每一档都保持 100%， 且**跨 seed 零方差**（六个桶全部 std 0.0）。语义回想并不随滞后单调下降——14–29 天的 78% 反而**高于** 7–13 天的 55%——因为摘要生成一次后不会随年龄改变。它丢的是压缩在 生成时丢掉的东西；**时间不是变量**。

方差一列很有信息量，且我们已把它量化。精确回想是确定性的（每桶 std 0.0，因为读取器在解析引用链）。语义回想的离散来自 **LLM 采样**，而且**很大**：取两个真实生产窗口，把其原始条目导入独立实例，各自用 `recompute` 重新总结 **5 次**（输入相同、参数相同， `temperature` 保持端点默认 0.7）：

来源窗口	输入	五次输出长度	长度 SD	版本间平均相似度
2026-09-15	12 条 / 13724 字符	1789, 1686, 1332, 1205, 1258	**265**	**0.263**
2026-09-12	33 条 / 29198 字符	2350, 1562, 1456, 1432, 2189	**437**	**0.250**

同一窗口的两次总结**只有约四分之一的文本重合**。差异是实质性的、不是措辞层面的——同一天一次写成「权限为 `admin-only`」，另一次写成「团队权限链路重构（A1/A2）」。所以摘要的桶均值是**宽分布的中心**而非精确值，单次运行的分桶数字只有指示意义，本节的 day/week 对比也带着这份离散。

一处值得记录的更正。 本节初稿用「237 与 453 字符」作为采样方差的证据。那个数字来自调用两次 `recompute` 后比较 `mem/recall` 的两次返回——但 `recall` 会把**该窗口的全部历史版本按最新在前拼接返回**，所以第二次返回是「第一版 + 第二版」，不是第二个样本。那个数字测的是**累积**，不是方差。上表来自正确地逐次重跑、每次只读一个版本。

3.2b 统计功效：当前样本量能支撑哪些论断

分桶准确率基于 2–14 个探针，且原先只报裸百分比——这正是评审反对的呈现方式。下表给出 95% **Wilson** 区间（小样本二项比例的合适区间；正态近似在这些样本量下会给出 [0,1] 之外的界）：

滞后	精确	近因窗口	天级摘要	周级摘要
1	100% [34,100]	100% [34,100]	100% [34,100]	0% [0,66]
3–4	100% [51,100]	0% [0,49]	25% [5,70]	0% [0,49]
7–13	100% [79,100]	0% [0,22]	57% [33,79]	29% [12,55]
14–29	100% [61,100]	0% [0,39]	67% [30,90]	33% [10,70]

各桶 n 依次为 2、4、14、6。

哪些成立、哪些不成立。 以「区间不重叠」为保守判据：

对比	滞后 1	7–13	14–29
精确 vs 近因	重叠	**不重叠**	**不重叠**
精确 vs 一次性压缩	重叠	**不重叠**	**不重叠**
天级 vs 周级摘要	重叠	**重叠**	**重叠**

所以本文的核心论断——有界近因窗口与有损压缩器**无法回答它们已不再持有的内容**，而精确回想可以——在其真正要紧的滞后档位上**由数据支撑**。但**天级与周级的差异不成立**：每桶仅 6–14 个探针时， 区间处处重叠，要分辨观测到的差距大约需要**每臂 35–46 个探针**（80% 功效，计算见 `stats_intervals.py`）。因此我们把该排序作为**观察**而非**发现**来报告； §3.2(d) 的成本对比 （关于 token 而非准确率）不受影响，因为它依据的是实测 token 数。

这对后续研究设计意味着什么。 容量断崖（精确 vs 近因）在本文的样本量下即可检出； 摘要层级的对比则不行，功效计算说明差距真实存在、但需要约三倍的每桶探针数才能确立。 **这是本节产出的最有用的一个数字：评估摘要层级的召回需要每桶 $n \approx 40$，而不是 $n \approx 10$**。

3.2c 校验 token 分类器

§4 与 §5 里每一个存活数字都由三个正则产出，而我们**从未检查过它们的精确率与召回率**—— 更没在占语料大头的中文文本上检查过。若数量检测器漏掉带单位的量、或标识符检测器漏掉整个命名法， 那么「标识符活得比数量久」这一结论就可能是**检测器的产物而非摘要的性质**。因此我们手工标注了 47 个取自语料自身用词的对抗性用例（`validate_classifiers.py`），并据此打分。第一次运行就暴露了真实缺陷：

分类器	精确率	召回率	F1
numeric（修正前）	0.72	0.74	0.73
symbol（修正前）	0.57	**0.22**	**0.32**
causal	0.85	1.00	0.92

标识符检测器只覆盖小写开头的驼峰与下划线命名，漏掉了 `UPPER_SNAKE_CASE`、`PascalCase`、 下划线打头的名字与连字符标识符 —— `materialize`、 `WritePipeline`、 `OP_PUSH_CONSTANT`、 `g_runtimeStaticEnd`、 `CertificateVerifyMode` 全都不算。**它对 78% 的标识符视而不见， 而标识符恰恰是本文声称存活最久的那一类**。 数量检测器有镜像的问题：忽略单位后缀 （`256MB`、 `30-60MB`、 `31x`），并把时间戳的各个组成部分、以及 `sha256` 里的年份当成数量。

两者都已重写（抽取前先剥离时间戳；数量可带单位/区间/倍数；标识符覆盖四种命名法， 且反引号片段按空白拆开），重新打分：

分类器	精确率	召回率	F1
numeric（修正后）	**1.00**	**0.97**	**0.99**
symbol（修正后）	0.78	**0.78**	0.78
causal	0.85	1.00	0.92

修第一对缺陷时又暴露出两个缺陷，而两者都会**与摘要无关地压低**所测保留率：数量模式把尾随空格 带进了 token（`'101 '` 而非 `'101'`，于是拿它去摘要文本里做存在性判断会失败）；其词边界用的 `\w` 会匹配中

日韩字符——所以「堆上限由 256MB 提到 1GB」里的 `1GB` 因 `GB` 后面是汉字而被否决。 标识符模式还接受了尾随连字符（`--el-button-`）。修掉之后 numeric 达到 1.00/0.97； 唯一剩下的漏检是 `sha256` 里的 `256`，而那是算法名的一部分，本就不该算。

要紧的问题是论文结论是否依赖那个缺陷，所以我们用修正后的检测器重跑真实语料测量。**不依赖**：

输入天数	对数	数量	标识符	因果	长度比
1	37	85%	94%	89%	0.90x
⩾2	15	59%	58%	53%	0.54x

与 §4.2 修正前的数字（90/97/90% 于 0.94x、58/65/48% 于 0.53x）相比图景未变， 且标识符的优势是**收窄而非扩大**——也就是说修正**不利于**本文的主张，而不是有利于它。 剩余的假阴性属口径分歧而非漏检（`284 MiB` 该不该连单位一起算、`.` 是否分隔标识符）， 而因果分类器的两个假阳性（`所以然` 里的 `所以`、非因果用法的 `为了`）是真实的语义歧义—— 我们把这些保留在标注集里，而不是按检测器的方便去改标注。

3.3 消融：断崖确实随容量移动

若（a）是容量效应，移动窗口就必须移动断崖。六档窗口，只用本地后端（不需实例、不调 LLM）； 图 2 画出结果：

top_k	预测断崖（top_k ÷ 10 事件/天）	实测断崖	整体
10	1.0 天	≤0 天	0.0%
20	2.0 天	≤1 天	6.2%
30	3.0 天	≤2 天	12.5%
50	5.0 天	≤3 天	25.0%
100	10.0 天	≤5 天	56.2%
200	20.0 天	≤7 天	93.8%

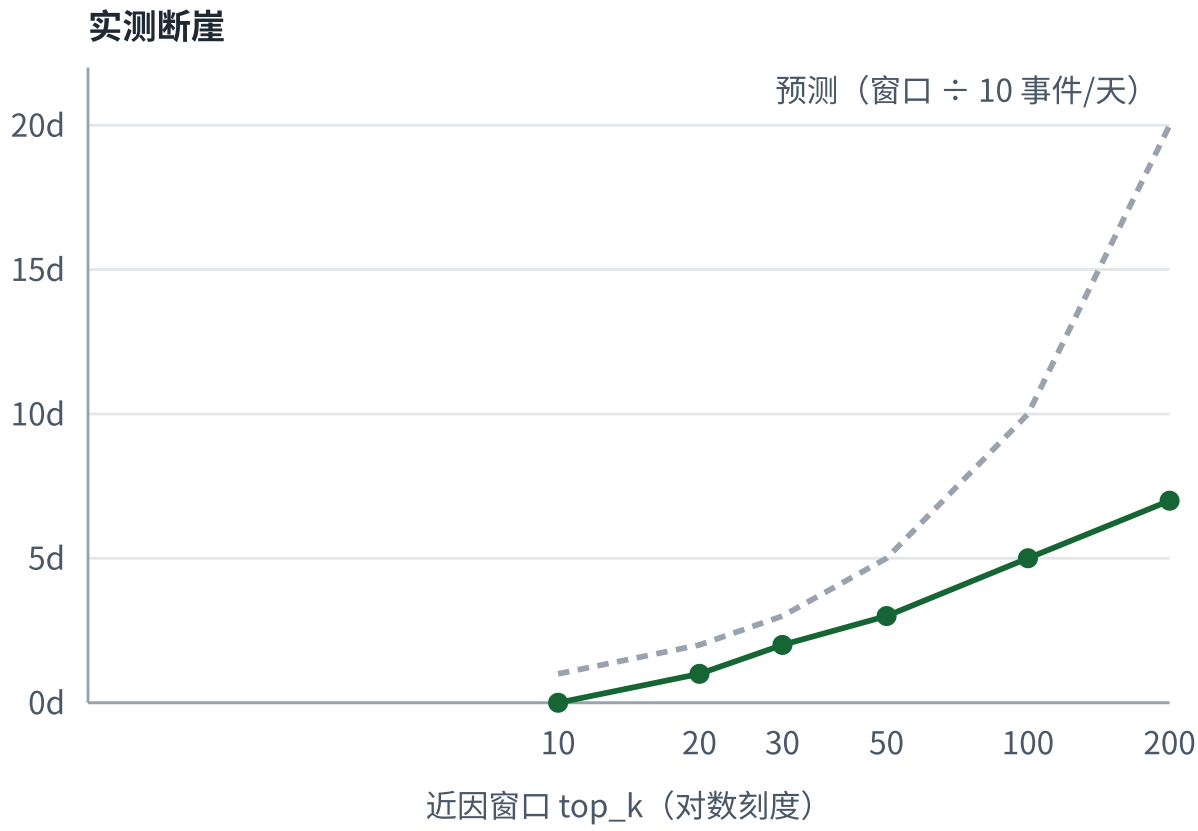


图 2. 消融：实测断崖随窗口容量移动。灰色虚线是预测——容量为 `top_k` 条的窗口覆盖 `top_k ÷ 10 事件/天` 天；绿线是实测。实测略低于预测，因为桶边界稀疏——断崖只能落在边界上，而相邻那一桶要求其中每个探针都答对。

断崖单调移动（0→1→2→3→5→7）。若它不管窗口多大都停在 2 天，容量解释就被推翻， 差异就必须用抽取器或探针构造来解释。实测略低于预测，原因有二且都不是缺陷：桶边界稀疏 （断崖只能落在边界上，而中间那档要求其中**所有**探针都正确），以及 `top_k=200` 的两个 错误来自 29 天的探针，20 天的窗口覆盖不到。

（d）粗层不是细层的廉价版，而是另一种取舍。 直觉的说法会是「读周摘要，拿到更短的答案」。 测量结果相反：

臂	准确率	每问 client token	每问 server token
`chronomem day`	53.1%	**88**	37 500
`chronomem week`	18.8%	**195**	43 750

周级臂每问读的文本更多，而不是更少，答对率却只有约三分之一。 原因在单条响应里看得见。 问第 1 天的 `ZR01` 选了什么，天级摘要写的是 `ZR01 (bob): 选择方案 A`；周级摘要写的是：

> Day 1 至 Day 6 期间，针对 ZT02、ZR01、ZV04、ZU03… 等项目的 … 模块，依次选定 Option A/B/C

十个引用号、一句话，而**引用号到选项的对应关系没有了**。周文本比天文本更长（764 对 343 字符）， 因为它必须提到六天的标识符——但它提的是**名单，不是答案**。

因此粗层的成本画像不是「输出更小」，而是**「摘要的摘要」在压缩时丢掉了条目与其取值之间的配对**， 同时保留了条目的名字。这与 §5.2 在真实数据上的发现一致——标识符比附加其上的数量与机制活

得久—— 也意味着：一个需要某条具体事实的客户端，并不是在为更粗的答案付更少的钱，而是在付**差不多的钱 买一个可能根本不包含该事实的答案**。

分层设计仍是月级召回得以可能的原因——精确回想在每一档都是 100%，天级也保住了一半以上—— 但收益**不来自粗摘要便宜**，而来自它下面那些细层仍然可用；超出最粗层级的部分，则由直接对原始序列分页覆盖（§7）。

这是 §4 从另一个方向刻画的同一机制。在那里，由**单天**摘要构建的周摘要与其输入逐字节相同 （无压缩、无损失）；在这里，由六天构建的周摘要确实做了合并，并丢掉了条目与取值的配对。 **粗层的保真度取决于其输入有多多样，成本取决于它必须点多少名字**——两者都不由层级位置决定。

---

4. 递归步：保真度取决于输入多样度

4.1 为什么最直觉的测量是错的

我们要刻画的这一步是：*某项目在一周内的摘要 → 该项目的周摘要*。把它测成 *某一天的摘要 → 该周的摘要*是无效的，因为周覆盖五到七天、长约 3.4 倍， 保留率被「目标文本单纯更大」抬高了。

在同一份 24 天样本上两种口径都测：

比较	目标长度	数量保留
天包 vs 周包（范围不对等）	中位 13143 字符 vs 3440	**42.2%**——粗层看起来**更保真**
同项目，一天 vs 该周的对应段	范围不对等	**约 81%**
同项目、同一 7 天窗口（本文采用）	范围对等	见下

第一行就是破绽：一个**粗层比细层更保真**的测量，测的是文本长度，不是压缩。

4.2 真正的结果

52 个项目-周对，来自已闭合的周。输入规模是该周内此项目**确实有摘要的天数**。 图 3 画出保留率与输入规模的关系。（此处数字为 §3.2c 检测器修正后的重测结果； 修正前为 29/11 对、90/97/90% 与 58/65/48%。）

输入天数	对数	数量	标识符	因果连接词	长度比
1	37	**85%**	94%	89%	**0.90x**
≥2	15	**59%**	58%	53%	**0.54x**

单输入的情形大多是复述，而非压缩——但并不整齐划一。 初稿在这里把结论说过头了， 而纠正它是要紧的：我们曾写「周摘要与其单天输入**逐字节相同**」。用经校验的检测器重测全部 37 个单输入对后，看到的是三种形态而不是一种：

长度比（周/日）	对数	占比	解读
⩾ 0.95	**25**	68%	该步复述了输入
0.70 – 0.95	5	14%	部分压缩
< 0.70	**7**	19%	真正压缩

被复述的那些里确有逐字相同的（`cangjie_stdx`、`xisp`、`tang`、`json-rpc`、`a2a-cj` 等长度比恰为 1.000）—— LLM 逐字复现上千汉字不叫总结，叫复制。但**19% 的单输入对确实大幅压缩了**（`atelier-starline` 0.43 倍、`mcp` 0.47 倍），所以「单输入即不压缩」作为规律是错的。 成立的是聚合结论：单输入平均 0.90 倍，多天输入平均 0.54 倍。

对指标口径的影响不变——单输入区的「90% 保留」主要反映该步**拒绝压缩**，而非「无损地压缩」—— 但这个机制是**倾向**，不是定律。

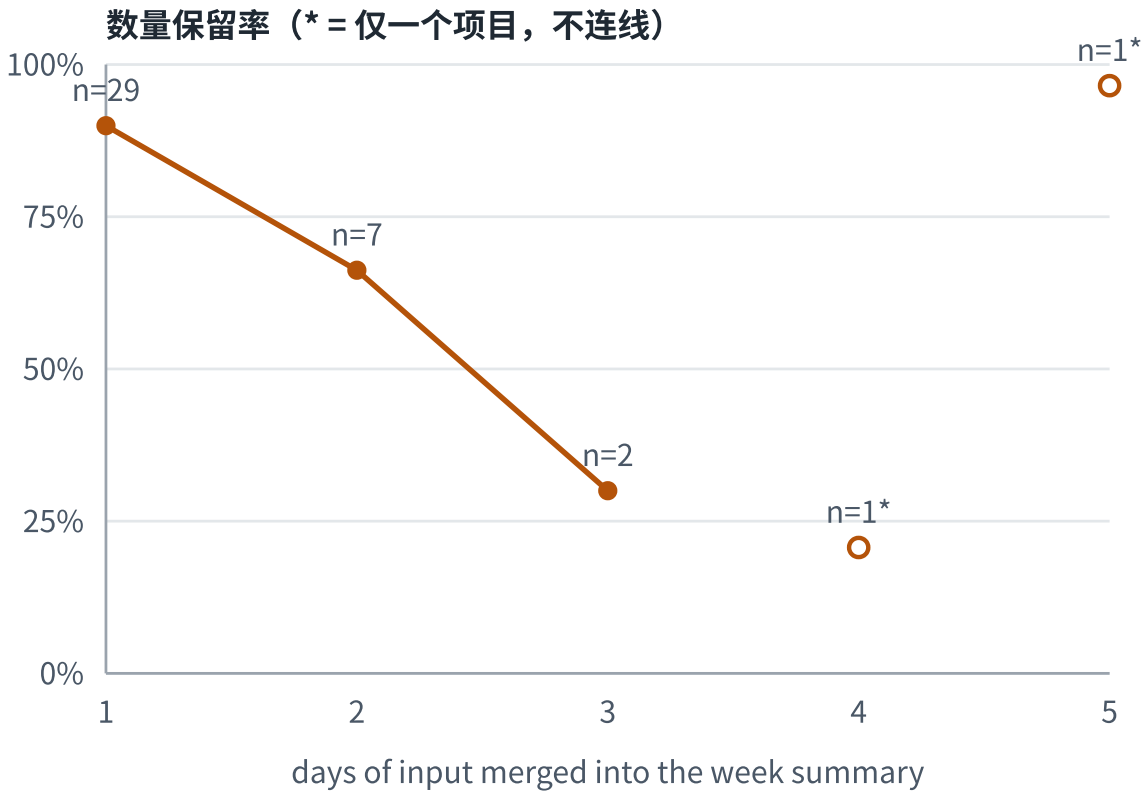


图 3. 递归步按「被要求合并多少」成正比地损失。数量保留率 vs 合并进该项目周摘要的输入天数。单天点（n=29）接近 100%，因为该步在**复述**输入而非压缩它；需要合并的天数越多、保留越低。标 `*` 的点只含一个项目，绘制但不连线，否则单个观测会把曲线带偏。

压缩只在输入多样时才出现。输入达到两天及以上时，该步把文本减半（0.53x）， 数量保留降到 58%、因果连接词降到 48%。趋势随输入规模延续：

输入天数	长度比	数量保留
1	0.94x	90%
2	0.64x	66%
3	0.15x	30%
4	0.20x	21%

4.3 推论

（a）跨输入规模平均会抬高保真度。 把 29 个单输入对混进平均，长度比从 0.53x 变成 0.82x， 表观保真度显著上升。任何对递归总结器的评估都**必须按输入多样度分层**， 否则会把「什么都没做」的那些情形当成成功来报。

（b）两跳差一个数量级。 `原始 → 天` 压缩 3.1–4.2 倍；`天 → 周` 压缩 0.53 倍。 原因不是层级而是输入：第一跳吃的是原始条目，第二跳吃的是已经被压过一次的摘要。 因此「每层压缩比固定为 k」并不是这套架构的属性。

（c）这条链不是定点压缩器。 保真度由「该步被要求合并什么」决定，所以 「每一层压缩 k 倍」这类说法不成立。成立的是：**这条链从不丢失它没被给到的信息， 且压缩量正比于输入的多样度。**

4.4 一个独立的词汇度量复现了同一排序

评审询问除语义路线（§2.5）之外，是否试过 n-gram 重合、ROUGE 或编辑距离来替代 token 指标。 我们试了，而**定位很重要：这些仍是词汇度量**。它们比较表面序列，因此**不能**弥合评审指出的缺口—— 换个说法复述的事实，在 ROUGE 上得分低，正如它在 token 存活上得分低。它们能检验的是另一件更窄的事： **token 指标内部的具体选择**（哪些类别计数、如何做存在性判断）是否**偏置**了天级与周级的排序。 若完全不共享这些选择的度量复现出同一排序，那么该排序就不是 token 设计的产物。

在 §4.2 的同一批 52 对上测量，ROUGE-L 用**字符二元组**（语料是中文，没有词边界）：

度量	1 天输入	≥2 天输入	差距	P(单天 > 多天)
长度比	0.898	0.539	+0.359	—
ROUGE-L F1	0.909	0.593	+0.316	0.881
编辑相似度	0.890	0.376	+0.513	**0.935**
token：数量	0.851	0.592	+0.259	0.773
token：标识符	0.939	0.580	+0.360	0.831
token：因果连接词	0.895	0.528	+0.367	0.695

每个度量都以同一方向区分两种形态，而**基于序列的度量区分得至少同样明显**—— 完全不使用 token 逻辑的编辑距离是六者中判别力最强的。所以天级与周级的差异**不是 token 指标设计造成的**。

它做不到的是验证该指标的语义。日文本与其周段之间高的 ROUGE-L 只意味着表面相似； 它无法区分「逐字存活的事实」与「换词存活的事实」，而且如果说有什么区别，它对表面形式比 token 存活更敏感。所以评审的根本关切**依然开放**，弥合它需要一个可用的语义度量—— 而 §2.5 记录了我们在这个部署上拿不到。

---

5. 真实语料上什么活了下来

5.1 盲测：无 LLM 路径足以召回精确事实

设计。 我们先自己从工作日志里读出六个事实（一次 OOM 事故的根因与两项修复；一次重试/退避策略的变更及其理由；一次产品改名以及有意不改的部分；一处关于两个组件关系的文档订正；三天摘要缺失的根因；一次模型 A/B 对照及其 prefill 吞吐）。然后派一个 agent，其**唯**一信息源是经由 MCP 的记忆服务——不访问仓库、不上网、不用先验知识——向它提出这六个问题。

结果：6/6 全对，且全部经由 `exact` 路径（沿引用链下钻，回路中不调用 LLM）答出。答案包含精确的操作细节：常驻内存 30–60 MB 对瞬时峰值 217–240 MB、堆上限由 256 MB 提到 1 GB、prefill 吞吐 317 对 267 tok/s，以及改名时有意保留的那几个键及其理由。

这正是 position 论文关于成本不对称的主张，现在是被**测量**而非被论证的：**单靠无 LLM 路径就能召回两个月前的具体操作性事实**。 它不表明所有值得保留的东西都被保留了——只表明被保留下来的那些是可召回的。

同类的一个更小的测试在 36 小时合成 trace 上给出：摘要路径 3/6，而精确路径 6/6——即摘要丢掉了原始条目仍保留的事实。

5.2 链上先丢什么，按什么顺序

在同一语料上，最先损失的是**量化证据**与**因果机制**；专有名词与标识符存活最久。以下案例每一条都通过取回三个层级并检索该事实的词项核实过：

- *数量。* 一次打包清理把清单从 244 个文件收到 101 个。两个数字在天级与周级摘要中都不存在，留下的是「0.4.1 版已发布」。一项下载护栏从 1/3 提到 3/3，峰值 RSS 恒定在 284 MiB；周摘要里 `护栏`、`3/3`、`284` 一个都没有。
- *机制。* 「排序比较器拿一个含 `@version` 的标签当主键，于是版本序退化成字典序」，在两个更粗的层级上都只剩**「排序」**这一个词。标识符 `pkgLabel`、`@version` 以及「字典序」全部消失。
- *规则是最脆的。* 可复用的规则（「改内置函数语义前先查 API 文档」）几乎从不以规则形态存活；它们只在一条不相干的待办（「同步 docs-site」）里留下痕迹。

两点限定。其一，**被用来下结论**的数量会被丢掉，而充当**状态或验收口径**的数量常常存活——所以不是「数字会丢」，而是「**证据性的数字会丢**」。其二，这个顺序只在**真正发生压缩**处成立（§4）：单输入情形什么都不丢，因为什么都没压。

5.3 一个运维层面的发现：一次总结失败留下了持久缺口

该部署的周摘要覆盖了 6 个已闭合周中的 4 个。缺失的两周（09-07 与 09-14）并非随机缺席：同一时期的一个调度缺陷（compact 条目超出端点的 32768 token 上下文 → HTTP 400 → 失败 → 无限重试）导致总结器有两天**产出为零条记录**，而工作日志路径不受影响。正常批次在周一 00:10–00:20 生成；那两周从未出现在这个节奏点上。

由于调度器只总结**最近一个已闭合窗口**，缺口持续存在。补算这两周（对每个窗口显式调用一次 `mem/summarize`）把周覆盖恢复到 6 周，并把链式测量从 0/6 可召回提升到 3/6。

我们报告这一点，是因为它是合成基准**无法产出**的那类证据：**记忆系统自身的一次故障，在它自己的记忆里留下了一个可测量、可持久的缺口**，而缺口的形状（恰好限于故障期、天级摘要完好）指认了成因。

6. 方法论：两个陷阱与一个负面结果

6.1 陷阱一——一个把结论反转的长度假象

把整天摘要对整周摘要比较，得到的是**周层的保留率高于天层**（数量上 42% 对 29%）。作为一个压缩主张，粗层比它的输入更保真是**不可能**的，而原因是算术：周包长约 3.4 倍、多覆盖六天，所以某个 token 更可能因巧合而出现。把两侧都限制到同一项目同一窗口后，顺序就反了过来（§4）。

推广。 任何在长度与范围不同的文本上算出的保留指标都值得怀疑。破绽是**与机制相矛盾的排序**。

6.2 陷阱二——一个把失败制造出来的抽取歧义

探针原本按（主题，天）定位答案。摘要的散文结论惯常把多个主题与多个选项写进一句话（「keb 与 vun 分别应用了选项 A 与选项 C」），于是取首个选项字母的读取器会返回另一个主题的答案——而那个错误答案是**貌似合理的**，所以看起来不像 bug。分层后端显示的每一次失分都追溯到这一点；改为逐事实的不透明引用号后，该后端得 100%。

推广。 当某个后端的失败集中在一个答案取值上时，先怀疑读取器，再怀疑系统。

6.2b 陷阱三——打包段里返回相邻事实的答案

摘要把一天压成一行是常态：`- Day 1: ZT02 选方案 B (keb), ZR01 选方案 A (rix)`。取段内首个选项的读取器会用 `B` 回答 `ZR01`。那个字母是同一段里的合法选项，所以这次失分看起来像「答错了」而不是读取器 bug——而且**层级越粗、事实被压得越密，该假象越强**。它让粗层臂在六天以内的每一档都报 0%，而正确选项就在文本里。

修法是位置感知的：定位引用号，读它**之后**的选项（当引用号跟在选项之后时，读它**之前最近**的那一个）。

推广（陷阱二与陷阱三）。 当某个后端的失败集中在一个答案取值上，或当它们只出现在某一层而正确答案明明就在文本里时，**先怀疑读取器，再怀疑系统**。

6.3 负面结果——LLM 判定者夸大了丢失

判断一个事实是否「存活」在机械上并无定义，于是我们在同一批材料上跑了独立的 LLM 判定者。它们的输出自信而详细。在我们深入核验的具体主张中，**两个都错了**：

判定者的主张	核验
同一周的周摘要逐字节相同（同一 md5、15796 字符）	☑ **成立**
周摘要「就是最后一天的天摘要集合」	✕ **推翻**——逐日比对只有 0–1 个分组逐字相同
某天的摘要「完全略去了 chronomem 组；整条因果链与全部数字都没了」	✕ **推翻**——该组存在且完整，包含根因链与 `OOM`、`sseCond`、`CLOSE_WAIT`、`心跳` 等词

两个被推翻的主张朝**同一个方向**偏：断言了一个并不存在的缺失。判定者的**计数**（intact / partial / absent 分布）同样因此不可引用。

判定者仍有一项用处：它们**指向了正确的现象**——周输出逐字节相同这件事是真的，而发现它引出了 §4 按输入规模的分析。但方向与数字必须来自机械的重新测量。

6.4 我们因此依靠什么

§3–§5 中每一条量化主张都来自可重新运行、且输出随仓库归档的脚本：带 seed 的 trace 生成器、五臂运行器、消融、token 存活与递归步测量、以及链式核查。判定者的输出也归档了，但标注为仅作方向参考。工具本身有 31 个回归用例，外加一个变异检查——它刻意以十一种方式破坏实现（包括上述陷阱），如果测试套件没有察觉就判失败。这些是在 §6.1–6.2 的陷阱之后补的，**因为如果测试从未碰到它所声称覆盖的东西，测试通过本身说明不了什么**。

---

7. 局限

- **三个 seed。** 合成结果基于 seed 7/11/23。精确回想在各桶零方差，使其 100% 稳健；摘要数字带有高达 38% 的分桶标准差，应读作中心而非点估计。摘要每桶只有 2–14 个探针。
- **合成 trace。** 机制层面的结论（容量断崖、破坏性压缩）可迁移；依据本 trace 标定的量级不可。
- **真实语料没有标准答案。** §5 是存活测量与盲测召回，不是准确率。§5.1 表明被记录下来的东西是可召回的；它无法表明重要的东西都被记录下来了。
- **判定者覆盖不完整。** 计划四片判定（24 天），两片产出（12 天）。由于判定者的计数不可引用（§6.3），这只影响定性色彩，不影响所报告的数字。
- **单一部署、单用户、约两个月。** 未验证多租户、鉴权或加密运行；规模是少数几种类型、数千条记录。
- **只测了 `天→周` 这一跳。** 服务也支持更细的层级（`10min` / `30min` / `1h` / `3h`），本文未刻画其行为；本文使用的 trace 也只声明了 `[day, week]`。
- **层级链止于 `week`。** 这决定了「更长跨度」能意味着什么。服务认识 `month` 层级，但没有 `quarter` 或 `year`，而生产 `worklog` 类型两者都未启用；**超出最粗已启用层级的跨度不会被更粗地总结，而是由 `exact` 路径 + 对原始序列分页覆盖**。我们的测量与该做法「足够」而非「权宜」相符：精确回想在 29 天以内的每一档都是 100%，且读取器自动翻页（实测：300 条跨 2 页，无截断）。尚未测量的是**原始序列本身长到翻页不再实用**的那种跨度——这是部署的量级问题，不是总结层级的封顶。
- **压缩只有一种实现。** 一次性压缩基线是我们自己的；更强的压缩器会改变它的数字，但不会改变那个结构性论断——它无法回答关于已被它丢弃的内容的问题。

---

8. 结论

我们着手执行 position 论文的评估计划，结果发现最有意思的东西关乎**测量本身**。

对照部分是明确的：有界近因窗口在容量以内满分、超出则完全没有，而六点消融显示断崖随容量移动；一次性压缩即使最短滞后也是零分；分层的精确回想在整个跨度上保持 100% 且零方差。position 论文所论证的成本不对称是真实且可测的：单靠无 LLM 路径就答对了 6/6 个关于两个月前操作性事实的盲测问题。

递归总结部分要求我们**三次修正自己的方法**——先是测量口径，再是一个被我们说过头的论断，然后是那个论断所依赖的 token 检测器——而修正后的结果比原来的说法更具体。**该步的保真度由输入多样度而非层级决定。** 当某项目只贡献一天时，该步**多数情况下拒绝压缩**：68% 的此类样本长度比 ⩾0.95、多份与输入逐字相同，所以表观的 85% 保留主要意味着该步没有去做那件事（19% 的单输入对确实大幅压缩，所以这是**倾向**而非定律）。当合并若干天时，文本减半，且一步之内约 40% 的数量与一半的因果连接词消失。「每层压缩比」不是这套架构的属性。在真实数据上，损失的顺序是稳定的：先证据性数字，再机制，标识符活得最久——而**可复用规则的脆弱性是最可能在实践中要紧的模式**，因为规则本应是经验中可泛化的那部分。

最后，作为本身就成立的结果，我们报告**测量工作自身**发现的东西：一次 token 分类器校验，发现标识符检测器漏掉了它本该统计的 78% 的标识符（已修；结论稳健，且修正**不利于**本文主张）；两个在查出前都产出了貌似可信的错误结果的测量陷阱；一份功效分析显示天级与周级的差异在所用样本量下无法分辨、需要每桶约 40 个探针；一处**服务配置缺陷**曾把 embedding 端点的语义区分度压缩到三十分之一，而我们一度错误地认为它改不动；以及由该修复**暴露为无效**的语义存活设计（其对照比事实本身更像目标窗口），我们把它作为**失败的测量**报告，而不是它表面上给出的「15 比 0」；还有一个关于评估方法本身的负面结果：独立的 LLM 判定者产出过具体而经不起核验的主张，我们深入核验的两个都错了，且都高估了丢失。因此本文结论建立在机械的、可复现的测量之上，判定者的输出只用于指示该往哪里看。

参考文献

（沿用 position 论文的参考文献表。新增引用的制品：）

1. Position 论文：*Chronomem (忆时塔): Time-Layered External Memory as an MCP Service for Agent Recall and Summarization.* AiraXiv 2610.0035.
2. 评估工具与结果归档：实现仓库中的 `chronomem/bench/` 与 `chronomem/bench/results/`。
3. 综合评估文档：`chronomem/docs/evaluation-retention.md`、`chronomem/docs/evaluation-real-corpus.md`、`chronomem/docs/evaluation-baseline.md`。

AI 使用披露

实现、评估工具与本文分析均与一个 AI 助手（DeepSeek）协作完成。独立的 LLM 判定者被用作**反例**：其输出作为负面结果报告于 §6.3，且不是任何量化主张的来源。所有报告的数字都由随仓库归档的脚本产出，并在撰写过程中与该输出逐条复核。